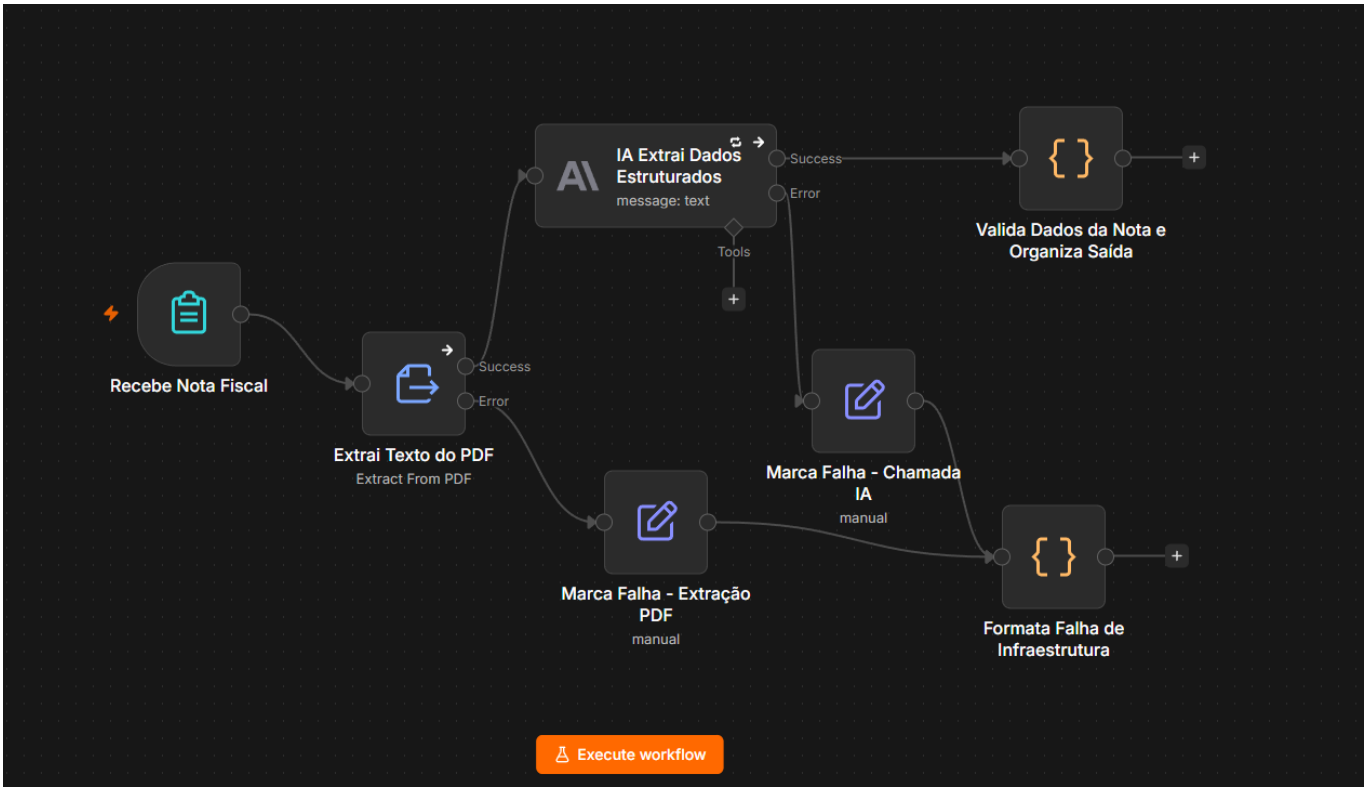
Extração de dados de notas fiscais

Documentação do trecho implementado (Parte 2)

Gustavo Rabutske, setembro de 2026

Este documento cobre o trecho que vai do recebimento da nota até a extração e estruturação dos dados. Checagem de duplicidade, lançamento em registro central, notificação e aprovação estão descritos no Desenho da Solução Completa e ficam fora desta implementação.

1. O que o fluxo faz



Fluxo implementado no n8n. O caminho de cima é a extração; o de baixo, o tratamento de falhas técnicas.

Recebe Nota Fiscal. Formulário do n8n com upload de PDF e seleção da empresa do grupo. Os dois campos são obrigatórios e o upload aceita apenas arquivos .pdf. Simula, para fins de teste, o gatilho de e-mail descrito no Desenho da Solução.

Extrai Texto do PDF. Lê o conteúdo textual do arquivo enviado.

IA Extrai Dados Estruturados. Envia o texto ao Claude Haiku 4.5, que devolve um JSON com número da nota, valor, vencimento e centro de custo, mais a razão social e o CNPJ do fornecedor e do destinatário. O prompt define o formato de cada campo (valor com ponto decimal, data em AAAA-MM-DD) e instrui o modelo a devolver nulo em vez de inferir quando o dado não está no documento. Em caso de falha técnica, a chamada é repetida automaticamente até três vezes, com intervalo de cinco segundos, antes de desviar para o tratamento de erro.

Valida Dados da Nota e Organiza Saída. Interpreta a resposta: remove formatação acidental, verifica se o JSON é bem formado, normaliza valores nulos e identifica quais dos quatro campos obrigatórios vieram preenchidos. Se todos vierem vazios, sinaliza que o documento provavelmente não é uma nota fiscal. Se alguns vierem vazios, devolve os dados extraídos marcados para conferência, em vez de descartar a nota inteira.

Marca Falha / Formata Falha de Infraestrutura. Caminho paralelo, ativado quando a leitura do PDF ou a chamada à IA falham por motivo técnico, independentemente do conteúdo da nota. A saída registra a etapa que quebrou, a mensagem técnica original e a ação recomendada para quem for operar.

2. Como operar

1. Abrir o link do formulário.
2. Anexar o PDF da nota. O formulário aceita apenas arquivos .pdf.
3. Selecionar a empresa do grupo correspondente à caixa em que a nota chegou.
4. Enviar e aguardar o retorno.
5. Ler a mensagem de retorno. Sem erro e sem conferência pendente, a nota está pronta para lançamento. Em qualquer outro caso, seguir a tabela da seção 6.

3. Como ler a saída

A saída distingue dois estados que costumam ser confundidos.

`erro: true` significa que não foi possível seguir. O documento precisa de tratamento antes de qualquer lançamento.

`revisao_parcial: true` significa que a nota pode ser lançada, mas com status de conferência pendente. O campo `campos_faltando` lista o que não foi identificado. Isso acontece com frequência em DANFE de mercadoria, que não costuma ter centro de custo.

4. Dependências

Credencial ativa da Anthropic para o modelo Claude Haiku 4.5. Instância ativa no n8n Cloud, na versão trial usada nos testes. Entrada esperada em PDF com camada de texto.

5. Responsável

Responsável técnico pela automação institucional, papel definido no Desenho da Solução Completa. Mantém o fluxo, monitora as execuções e cuida das credenciais.

6. O que fazer se quebrar

Mensagem que aparece	O que aconteceu	O que fazer
Extração parcial. Campos não identificados: …	A nota foi lida, mas um ou mais campos não existem no documento ou não foram localizados.	Lançar com status “Conferência pendente” e completar o campo faltante a partir do PDF. Se acontecer sempre com o mesmo fornecedor, avisar o responsável técnico.
Nenhum dado de nota fiscal foi identificado no documento.	Provavelmente o arquivo enviado não é uma nota fiscal.	Conferir o anexo e reenviar o documento correto.
Não foi possível extrair os dados da nota automaticamente.	A IA respondeu, mas o conteúdo não era um JSON válido.	Lançar manualmente a partir do PDF. Se repetir, avisar o responsável técnico.
Resposta da IA em formato inesperado. Requer revisão manual.	A chamada retornou, mas sem o campo de texto esperado na resposta.	Lançar manualmente a partir do PDF. Se repetir, avisar o responsável técnico.
Falha técnica na etapa: Extração do PDF.	Arquivo corrompido, protegido por senha ou digitalizado como imagem.	Solicitar reenvio ao fornecedor.
Falha técnica na etapa: Chamada à IA.	Indisponibilidade da API ou credencial vencida, após as tentativas automáticas.	Não reenviar a nota. Acionar o responsável técnico. Nenhuma nota é perdida, apenas fica pendente.

Em todos os casos a saída mantém o mesmo formato, com os campos `erro`, `revisao_parcial`, `mensagem` e, nas falhas técnicas, `acao_recomendada`. A intenção é que quem não escreveu o código consiga decidir o que fazer só de ler a mensagem.

7. Testes realizados

O fluxo foi exercitado com quatro layouts de nota fictícia e três cenários de falha.

Uma nota de serviços simples e uma NFS-e completa retornaram os quatro campos corretos. Uma DANFE densa, com dez valores concorrentes no documento (base de cálculo, tributos, valor dos produtos, linhas individuais), retornou o valor total correto e não confundiu a transportadora nem o banco com o fornecedor. Uma DANFE sem centro de custo e com duas duplicatas retornou os campos existentes e sinalizou os ausentes para conferência, sem inventar dados.

Nas falhas: PDF corrompido e indisponibilidade da API caem no tratamento de infraestrutura preservando a mensagem técnica; documento que não é nota fiscal é identificado pelo padrão de todos os campos vazios.

8. Dados pessoais neste trecho

O PDF enviado e o texto extraído passam pelo log de execução do n8n e ficam retidos nele. Nas saídas de erro de conteúdo, o campo `texto_bruto` carrega o texto integral da nota, que pode incluir nome civil quando o prestador é pessoa física. O acesso aos logs de execução fica restrito ao responsável técnico, com retenção definida entre 30 e 90 dias em vez de indefinida.

O texto da nota é enviado à API da Anthropic para a extração, o que configura transferência internacional de dados pessoais. Antes de qualquer uso em produção, essa etapa deve ser validada com a encarregada de dados, conforme previsto no Desenho da Solução Completa.

9. Premissas assumidas

A entrada é por formulário com upload, não por e-mail real, pelas razões descritas no Desenho da Solução Completa.

Assume-se PDF com camada de texto. Notas digitalizadas como imagem exigiriam uma etapa de OCR, fora do escopo desta fatia. Nesse caso o fluxo trata como falha de leitura, não como nota inválida.

Valor e vencimento são normalizados na extração (ponto como decimal, data em AAAA-MM-DD) para que o registro central receba dados prontos para ordenar e somar. O número da nota é preservado como impresso, inclusive zeros à esquerda, para não gerar colisão na checagem de duplicidade.

O centro de custo só é preenchido quando o documento traz esse rótulo de forma explícita. Pedido de compra, contrato e descrição de produto não são usados como substituto, porque um campo em branco sinalizado custa menos ao financeiro que um campo preenchido errado.

O Claude Haiku 4.5 foi escolhido por custo e velocidade, suficientes para o volume estimado. Se a taxa de conferência manual se mostrar alta em produção, avaliar um modelo maior é uma troca de uma linha no fluxo.

10. Fora do escopo

Checagem de duplicidade, lançamento em registro central, notificação ao gestor e aprovação, todos descritos no Desenho da Solução Completa.